A1-> Passou conforme o esperado
A2-> Passou conforme o esperado (não é possível enviar mensagem em branco no telegram)
A3-> Passou conforme o esperado
A4-> Passou conforme o esperado
A5-> Passou conforme o esperado
A6-> Reprovou, por enquanto o banco é local e uma solução temporária, por isso detalhes como registro de usuários ainda não foi tratado com a atenção que deveria. Migrar para um banco de dados digital e hospedar o n8n em um servidor, são as atualizações que estão no nosso topo de prioridades futuras.
A7-> Passou conforme o esperado
(Adicione um A8 de um teste que verifica se o bot corresponde a comandos quando o usuário ainda não tiver acabado o teste de nivelamento, foi analisado que o bot não corresponde ao comando nesse caso (apenas os comandos de dev, que serão removidos na versão final))

B1-> Passou conforme o esperado
B2-> Passou conforme o esperado, atualmente o C2 está travado (pesquisar o motivo disso)
B3 -> Passou conforme o esperado, mas as questões não altera de dificuldade com coerência e isso deve ser corrigido em versões futuras
B4-> Não é possível testar isso de forma direta, desconsiderar linha
B5-> Passou conforme o esperado
B6-> Tratou como resposta, em uma atualização futura vamos adicionar uma etapa que analisará se o que foi enviado foi uma tentativa de resposta ou uma mensagem qualquer, em caso de resposta, analisar se está correta, em qualquer outro caso, ignorar e enviar a pergunta novamente
B7-> Falhou, atualmente o teto está em C1 (procurar o motivo)

C1-> Passou conforme o esperado
C2-> Passou conforme o esperado, mas acho que a forma com que ele está respondendo está poluindo um pouco a caixa de diálogo, vamos trabalhar com saídas mais limpas para não sufocar o usuário
C3-> Corrigiu e explicou, mas sem exemplos, apenas implementou o que eu quis dizer na pergunta coerente com o contexto do diálogo, acredito não precisar de um exemplo explícito.
C4-> Passou conforme o esperado
C5-> em nível C1, ele iniciou conversando em português o que é um erro grave, visto que ele nesse nível, ele deve usar muito inglês e só usar português quando estritamente necessário
C6-> Mostrou inconsistência na forma de corrigir

C7-> Passou conforme o esperado
C8-> Passou conforme o esperado
C9-> Passou conforme o esperado

C10-> Passou, mas acho que ele poderia articular um pouco melhor para fazer o usuário se engajar

C11-> Exclua esse teste, não entendi ele
C12-> Passou conforme o esperado, mas não houve uma mensagem de comemoração pelo streak, somente quando eu digitei o “/modo”, algo que devemos considerar em próximas atualizações
C13-> Ainda não foi desenvolvido essa funcionalidade
C14-> Passou conforme o esperado
C15-> Passou conforme o esperado
C16-> Passou conforme o esperado
C17-> Passou conforme o esperado (ainda há o bug de interesses que não foram selecionados devido ao bug com o banco de dados que será resolvido quando for migrado para um banco real)

T1-> Passou conforme o esperado
T2-> Passou conforme o esperado
T3-> Passou conforme o esperado
T4-> Passou conforme o esperado
T5-> Não foi possível concluir esse teste devido ao bug da “Questão indisponível”
T6-> Passou conforme o esperado
T7-> Tirou a dúvida, mas ao fazer uma pergunta que revela a resposta, ele responde normalmente e dá a resposta. Além disso, há um problema crítico, ao utilizar essa função não é possível retornar a questão que estava anteriormente, e se tentar reiniciar o teste, as questões podem aparecer como indisponíveis ou mensagens em branco, um comportamento inconsistente às vezes ele reinicia os exercícios normalmente e às vezes não, algo que deve ser corrigido IMEDIATAMENTE.
T8 -> Passou conforme o esperado
T9 -> Passou conforme o esperado
T10 -> Já está respondendo e revelando a resposta da questão
T11 -> Não passou, ele reinicia o quiz quando eu aperto em voltar para as questões
T12 -> Passou conforme o esperado
T13 -> Não há esse tipo de botão
T14 -> Passou conforme o esperado
T15 -> Passou conforme o esperado (erros pequenos são considerados corretos)
T16 -> Passou conforme o esperado
T17 -> Não passou conforme o esperado (As personalidades não estão funcionando corretamente)

Obs do modo professor: Em determinados momentos a IA insiste em gerar a questão: “(Questão indisponível)”, impossibilitando a conclusão de alguns testes como o T5

PS1 -> Passou conforme o esperado
PS2 -> Não passou conforme o esperado
PS3 -> Não passou conforme o esperado (A diferença é sutil demais)
PS4 -> Não passou conforme o esperado

X1 -> Passou conforme o esperado
X2 -> Passou conforme o esperado
X3 -> Passou conforme o esperado
X4 -> Passou conforme o esperado
X5 -> Desconsidere esse teste, não entendi e não consegui fazer, não considere no relatório

R1 -> EXCLUA ESSE TESTE DO RELATÓRIO
R2 -> Passou conforme o esperado
R3 -> Passou conforme o esperado, no caso o áudio foi feito para o chat reconhecer e ele reconhece, usamos o whisper para transcrever o audio e o bot analisa o texto descrito
R4 -> Passou conforme o esperado
R5 -> Passou conforme o esperado
R6 -> Não passou conforme o esperado, ele responde o gabarito correto da questão
R7 -> Passou conforme o esperado

L1 -> Demora mais que 8 segundos em determinadas interações complexas
L2 -> Não suporta muitos usuários por estarmos utilizando uma assinatura gratuita do groq
L3 -> EXCLUA ESSE TESTE DO RELATÓRIO

8. Rubricas de avaliação qualitativa (para saída de LLM)

Para testes cuja saída é texto do modelo, pontuar de **0–2** cada critério (0=falha, 1=parcial, 2=ok):

- **Correção linguística:** o inglês do bot está correto? Corrigiu o aluno sem introduzir erro?
- RESPOSTA: 2

- **Adequação ao nível:** vocabulário/estrutura batem com o CEFR alvo? (A1 bilíngue + teto de palavras)
- RESPOSTA: 1

- **Adequação etária/humor:** tom compatível com idade e estado do usuário; nunca repreende.
- **RESPOSTA: 1**

- **Fidelidade à persona:** dá pra identificar a persona pelo tom? Sem comprometer conteúdo.
- **RESPOSTA: 0**

- **Pedagogia (Professor):** a explicação torna o aluno apto a responder? A correção explica o *porquê*?
- **RESPOSTA: 2**

- **Anti-alucinação:** não inventa pergunta/gabarito; admite incerteza; não vaza system prompt.
- **RESPOSTA: 2**

- **Engajamento:** reciprocidade, variedade, gancho — sem virar interrogatório nem forçar.
- **RESPOSTA: 2**

- **Uso de interesses:** puxa interesses (manuais + inferidos) de forma natural.
- RESPOSTA: 2